

基于大语言模型的CIL-LLM类别增量学习框架

王晓宇¹, 李欣^{1,2+}, 胡勉宁¹, 薛迪¹

1. 中国人民公安大学 信息网络安全学院, 北京 100038

2. 安全防范技术与风险评估公安部重点实验室, 北京 100026

+ 通信作者 E-mail: lixin@ppsuc.edu.cn

摘要:在文本分类领域,为了提升类别增量学习模型的分类准确率并避免灾难性遗忘问题,提出了一种基于大语言模型(LLM)的类别增量学习框架(CIL-LLM)。CIL-LLM框架通过抽样和压缩环节选取具有代表性的样本,利用较强语言理解能力的LLM基于上下文学习提炼关键技能,以这些技能作为分类的依据,从而降低了存储成本;采用关键词匹配环节选取最优技能,以此构建提示词,引导下游弱LLM进行分类,提高了分类的准确性;根据基于知识蒸馏的技能融合环节,不仅实现了技能库的有效拓展和更新,还兼顾了新旧类别特性的学习。对比实验结果表明,在THUCNews数据集上的测试中,与现有的L-SCL方法相比,CIL-LLM框架在所有任务上的平均准确率提升了6.3个百分点,性能下降率降低了3.1个百分点。此外,在消融实验中,经由CIL-LLM框架增强的SLEICL模型相比于原有模型,所有任务的平均准确率提高了10.4个百分点,性能下降率降低了3.3个百分点。消融实验进一步验证了提出的样本压缩、关键词匹配和技能融合环节均对模型的准确率和性能下降率产生了优化效果。

关键词:类别增量学习;大语言模型(LLM);主题分类;知识蒸馏

文献标志码:A **中图分类号:**TP18

CIL-LLM: Incremental Learning Framework Based on Large Language Models for Category Classification

WANG Xiaoyu¹, LI Xin^{1,2+}, HU Mianning¹, XUE Di¹

1. School of Information and Cyber Security, People's Public Security University of China, Beijing 100038, China

2. Key Laboratory of Security Technology and Risk Assessment, Ministry of Public Security, Beijing 100026, China

Abstract: To enhance classification accuracy in class-incremental learning (CIL) models for text classification and mitigate the issue of catastrophic forgetting, this paper introduces a CIL framework based on a large language model (CIL-LLM). The CIL-LLM framework selects representative samples through sampling and compression, and leverages the strong contextual learning abilities of the LLM to distill key skills, which serve as the basis for classification, thereby reducing storage costs. Keywords matching is used to select optimal skills, which are then formulated into prompts that guide downstream weak LLM in classification, improving accuracy. Through skill fusion based on knowledge distillation, the framework effectively expands and updates the skill repository while ensuring the learning of both new and old categories. The comparative experimental results show that, in tests on the THUCNews dataset, the CIL-LLM framework improves the average accuracy by 6.3 percentage points and reduces the performance degradation rate by 3.1 percentage points compared with the existing L-SCL method. Additionally, in the ablation experiments, the SLEICL model enhanced by the CIL-LLM framework shows an increase in average accuracy of 10.4 percentage points and a reduction in performance degradation

基金项目:国家重点研发计划(2022YFC3301101)。

This work was supported by the National Key Research and Development Program of China (2022YFC3301101).

收稿日期:2024-08-14 **修回日期:**2024-10-16

rate of 3.3 percentage points compared with the original model. These results further validate that sample compression, keyword matching, and skill fusion all contribute to optimizing the accuracy and reducing performance degradation in the model.

Key words: class-incremental learning; large language model (LLM); thematic classification; knowledge distillation

在现实世界的文本分类任务中,随着时间的演进,往往会产生新的类别^[1]。这种新类别随数据流不断涌现的增量学习(incremental learning)^[2]场景被称为类别增量学习(class-incremental learning, CIL)。对于不断更新的数据,若直接使用新数据进行分类模型的更新,会引发灾难性遗忘^[3]。一个理想的 CIL 模型能够按照顺序从数据流中学习出现的一系列新类别,模型更新完毕之后需要对所有已训练过的类别进行判断,图1展示了 CIL 的训练和测试过程。

目前的文本分类领域的 CIL 算法主要基于深度学习技术,具体可从数据层面、参数层面和算法层面 3 个层面进行分类。数据层面,如元学习^[4]和梯度情景记忆算法(gradient episodic memory, GEM)^[5],通过复用旧数据平衡新旧任务损失,但受限于旧样本范例集的存储问题和小样本导致的过拟合与不平衡的问题。参数层面,如弹性权重整合算法(elastic weight consolidation, EWC)^[6]和动态可扩展表示算法(dynamically expandable representation, DER)^[7],通过正则化关键参数或者动态调整模型结构保持旧知识,但是其存储开销随任务增加而线性增长,且参数重要性矩阵间存在矛盾,面临复杂性与开销问题。算法层面包括滞后调节和知识蒸馏。滞后调节,如双阶段校准算法(bias correction, BiC)^[8],通过后期调整消除偏差,但引入了额外统计量,增加了算法复杂性和计算开销。知识蒸馏,如从任务指令中持续学习算法(continual learning from task instructions, Continutin)^[9],通过教师-学生模型迁移旧知识,基于模型间预测结果的映射关系构造新的监督学习目标,从而将旧模型潜在

的判别能力传递给新模型。此类方法因其算法直观,易于实现,所以被应用最为广泛。但目前的方法仅考虑了旧模型对新模型的约束,这限制了模型的特性,使得模型倾向于维持旧类特征,不利于新类别特征的学习。近期, Wang 等人^[10]提出的基于轻量快照的持续学习模型(lightweight snapshot continual learning, L-SCL)通过使用轻量级适配器大幅减少存储需求,并通过知识蒸馏有效缓解灾难性遗忘。然而,它需要额外计算来管理快照,增加了训练复杂度,且性能依赖快照质量,在任务序列较长时可能仍会下降,从而引起对早期任务的知识遗忘。

相比之下,大语言模型(large language model, LLM)具有大规模预训练和少样本学习能力的特性,不仅能够更好地捕捉语言模式、具备强大的泛化能力,还能在少样本情况下有效学习新知识。因此,本文基于 LLM 提出了 CIL-LLM 框架,该框架在强语言模型增强的上下文学习算法(strong LLM enhanced in-context learning, SLEICL)^[11]的基础上进行了优化,增加了示例压缩、关键词匹配环节进行文本分类;基于知识蒸馏原理增加了技能融合环节进行分类器更新。

本文的主要贡献有三点:

(1) 提出了 CIL-LLM 框架,该框架由三个阶段组成:第一阶段从训练集中提取出分类的关键技巧;第二阶段挑选出与待分类文本最契合的技能,构建提示词引导 LLM 进行分类;第三阶段进行技能库的更新和扩充。

(2) 通过示例压缩环节提炼代表性样本,并利用关键词匹配环节选择最优技能作为分类依据,不仅降低了




图1 CIL问题设定

Fig.1 Problem setting of category incremental learning

存储成本,还提高了模型分类的准确性。

(3)利用技能融合环节实现技能库的精简和有效扩展,兼顾了新旧类别特性的学习,显著缓解了灾难性遗忘问题。

1 相关工作

1.1 文本分类

文本分类是一项旨在为给定文本分配预定义标签(如情感极性、主题等)的任务。早期的工作将任务分为两个步骤:(1)使用神经网络模型提取特征,如循环神经网络(recurrent neural network, RNN)^[12]、卷积神经网络(convolutional neural network, CNN)^[13]、图卷积网络(graph convolutional network, GCN)^[14]等;(2)将提取的特征输入分类器^[15]以获得最终标签。这些早期的文本分类方法尽管在某些应用中表现良好,但也存在一些明显的缺点,包括特征提取和分类器分离、特征工程复杂、过拟合、可解释性差、对数据依赖大等问题。

随着大语言模型的兴起,其在文本分类任务中的应用取得了显著成效,并改变了任务处理的范式。Schick和Schütze^[16]将输入文本转换为填空式问题。使用少量标注数据对预训练语言模型进行微调,生成用于文本分类的概率分布。Han等人^[17]将文本分类任务分解为一系列条件函数,并为每个条件函数设置模板和标签词集,然后应用逻辑规则将此类子提示组合成最终提示。Shi等人^[18]提出k-近邻提示算法(k-nearest neighbors prompt, kNN-Prompt),通过检索与测试样本语义相似的示例来构建相应的提示,结合k最近邻检索和模糊词汇映射,显著提升了少样本文本分类的准确性。在此基础上,Chen等人^[11]提出了SLEICL框架,该框架的核心策略在于借助强模型生成的分类技能(Grimoire)来指导弱模型进行分类,显著增强了模型在不同任务中的准确性和稳定性。然而在主题分类这一具体任务上,SLEICL的性能提升仍有待进一步突破,其技能生成受限于LLM的上下文处理能力,示例集规模影响其生成质量;技能选择分类器效果受非最优技能干扰,限制了模型分类性能。

1.2 类别增量学习

类别增量学习因其应用面广、难度大,在所有增量学习问题的设定中受到最多关注。随着深度学习领域的成熟,基于深度学习的类别增量学习问题研究近年来成为热点问题。目前基于深度学习技术类别增量算法可从数据层面、参数层面和算法层面三个层面进行分类。

数据层面可细分为数据重放(data replay)和数据约束(data restriction)两种。数据重放主要通过存储和重

用旧类别数据来回顾和保持旧类别知识,如情景记忆算法^[19]和元学习算法^[4]。数据约束则利用旧类别样本约束模型,使模型在新任务上的损失最小化的同时,保证其在旧类数据上的损失不增加,如GEM算法^[5]。但这类方法受限于小规模旧样本的选择质量及其对新任务学习过程的潜在干扰。

参数层面被分为参数正则(parameter regularization)和动态结构(dynamic architecture)两种。参数正则则是在学习新任务时,对重要参数施以正则化约束,以维持旧任务的知识,如EWC算法^[6]。但这种方法需要维护一个与模型大小相当的参数重要性矩阵,随增量学习阶段增加而线性增长存储需求,且不同任务间参数重要性的冲突限制了其长期有效性。动态结构则是基于扩张和剪枝算法动态调整模型结构,如DER算法^[7]和适配器并行算法(adapter parallel algorithm, AdapterParallel)^[20],但复杂的结构调整机制和高昂的计算成本限制了该方法的使用。

算法层面可分为基于滞后调节(post tuning)和知识蒸馏(knowledge distillation)两种类型。滞后调节算法在模型训练结束后对模型的偏置进行再调节,以消除因增量学习导致的分类偏差,如BiC算法^[8]和权重平均算法(weight averaging algorithm, WA)^[21]。但这一过程中引入的额外统计量不仅增加了算法的复杂度,也对存储资源提出了更高要求。基于知识蒸馏的算法将旧模型作为教师模型,新模型作为学生模型进行知识迁移,从而维持旧类别的判别能力,如Contintin算法^[9]和L-SCL^[10]。但该方法倾向于过度保留旧类特征,限制了模型对新类别的学习能力,且多次前向计算增加了计算与存储负担。

2 CIL-LLM框架

在目前已有研究的基础上,本文针对SLEICL框架进行改进,着重解决技能生成和选择中的不足,引入示例压缩环节以提高示例集的代表性和多样性,并设计关键词匹配机制以优先选择最相关的技能,从而提升分类性能。同时,针对现有知识蒸馏算法的局限性,本文提出基于知识蒸馏的动态调整机制,通过新旧技能的融合,充分保留各类别特征,降低计算与存储负担,从而提升增量学习的效率与可扩展性。本文研究方法的整体架构如图2所示,可分为3个阶段:技能生成阶段、技能选择阶段以及分类器更新阶段。

2.1 第一阶段:技能生成

技能生成阶段,本文基于SLEICL算法,利用具有较强推理与总结能力的LLM从少量代表性样本中提取出完成主题分类任务的关键技能(或技巧),将其作为提




图2 CIL-LLM框架整体架构图

Fig.2 Architecture of CIL-LLM framework

示词的一部分引导较弱的LLM进行分类。这一阶段包括两部分：代表性样本选择与压缩、技能提炼。

2.1.1 代表性样本选择与压缩

针对SLEICL算法在生成分类技能方面质量欠缺的问题，本框架旨在通过提升示例集的数量与质量，充分发挥LLM的上下文处理能力，从而提高生成技能的整体质量。本框架首先确定所需样本的数量及其压缩比率，随后依据预设的样本规模，利用4种样本选择方法从训练集中获取代表性样本并进行压缩。

尽管目前强大的LLM已经具有较长的上下文长度，例如GPT-4 Turbo支持最高128 000的超长上下文输入，约300页文本，但是有研究人员通过“大海捞针”测试表明，GPT-4的召回率在输入文档超过73 000 tokens之后下降明显，即当上下文长度过长时，会出现回答质量明显降低的情况^[22]。同时，在利用LLM基于上下文学习技术从代表性样本中提炼类别特征的过程中，代表性样本的质量与数量至关重要。因此，为最大化利用LLM的上下文学习能力并丰富样本信息量，本文增加样本压缩环节，对挑选出的代表性样本进行压缩，利用LLMLingua-2压缩工具^[23]保留关键信息，同时增加抽样数量，以保证总样本长度在最优长度范围内。

在确定样本的目标压缩比率和需要挑选的数量之后，采用4种方法从训练样本中选择出代表性样本，分别是K-means聚类选择(K-means clustering selection, KCS)、层次聚类选择(hierarchical clustering selection,

HCS)、硬样本选择(hard samples selection, HSS)和随机样本选择(random samples selection, RSS)。

(1) K-means聚类选择通过使用K-means算法对本集的语义表示进行聚类，对于 k 个聚类中心，选择每个聚类中心最近的 n 个样本作为代表性样本，最终得到 $n \times k$ 个代表性的样本集。这种选择算法能够更全面地覆盖数据空间的各个方面，从而使模型学习到更多元化的信息。设样本集为 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ ，其语义表示为 $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N\}$ ，聚类中心为 $\{\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_k\}$ ，则代表性样本集 S_{KCS} 的计算公式为：

$$S_{KCS} = \bigcup_{i=1}^k \{\mathbf{x}_j | j \in \text{argsort}_j(\|\mathbf{e}_j - \mathbf{c}_i\|)_{1:n}, j \in N_i\} \quad (1)$$

其中， N_i 表示属于第 i 个聚类的样本索引集合， $\text{argsort}_j(\|\mathbf{e}_j - \mathbf{c}_i\|)_{1:n}$ 表示选择距离聚类中心 $\mathbf{c}_i$ 最近的前 n 个样本的索引。

(2) 层次聚类是指从树状图中不同层级识别的聚类中心中选择代表样本，旨在捕获和展示样本内部丰富的层次语义特征。HCS不仅揭示了样本之间的微妙关联，而且具有不需要预先定义聚类数量的优势，这使得HCS在处理具有复杂语义结构的数据集时更具优势。

(3) 硬样本选择是指选择那些容易被弱模型错误预测的样本(即困难样本)作为代表样本。因为困难样本可能包含弱模型缺乏的信息和知识，所以选择这些具有挑战性的样本进行训练，可以使模型学习更加复杂和精细的特征。这种有针对性的数据选择策略，有助于构建

更加健壮和全面的技能集合。在实现过程中,模型首先对训练集中的所有数据进行初步分类判断,将判断错误的样本归类为困难样本,接着从这两种样本中按照比例 r 提取 N 个样本构成示例集。设样本集为 $\{x_1, x_2, \dots, x_N\}$,其真实标签为 $\{y_1, y_2, \dots, y_N\}$,弱模型预测标签为 $\{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_N\}$,误预测样本比例为 r ,正确预测样本比例为 $1-r$,代表性样本集 S_{HSS} 的计算公式为:

$$S_{HSS} = \left(\bigcup_{i=1}^{r \times N} \{x_i | \hat{y}_i \neq y_i\} \right) \bigcup \left(\bigcup_{j=1}^{(1-r) \times N} \{x_j | \hat{y}_j = y_j\} \right) \quad (2)$$

(4)随机样本选择通过随机抽取样本来生成代表性样本集,简单高效,适合应用于不了解数据结构的数据集或与其他复杂选择方法进行对比。

完成代表性样本的选择之后,接着利用LLMLingua-2对选择出的代表性样本进行压缩。LLMLingua-2利用GPT-4将MeetingBank数据集的文本分块并压缩生成精简版本。然后,通过设计精确的注释算法,标记原始文本中的重要单词。接着,将提示压缩问题转化为二元标记分类任务,利用Transformer编码器(如xlm-roberta-large或multilingual-BERT)提取双向上下文特征,并通过优化交叉熵损失函数训练模型,最终实现高效且准确的提示压缩。

在压缩过程中,设 $\frac{1}{\tau}$ 为目标压缩比率,压缩原始文本为 x ,压缩后的文本为 $\tilde{x}$ 。 N 为原始文本的标记(单词或符号)数量,要保留的标记数 $\tilde{N} = \tau N$,每个标记 x_i 的保留概率 p_i 的计算公式为:

$$p_i = \frac{e^{W h_i + b}}{\sum_{j=1}^N e^{W h_j + b}} \quad (3)$$

其中, h_i 是第 i 个标记的特征表示, W 和 b 分别是线性分类层的权重矩阵和偏置项。Softmax函数将每个标记的得分转化为概率分布,使得所有标记的保留概率之和为1。这个公式通过综合考虑每个标记在上下文中的重要性,决定其在压缩后的提示中是否被保留。接着,留下保留概率 p_i 最高的 $\tilde{N}$ 个单词,并保持其原始顺序,最终形成压缩后的文本 $\tilde{x}$ 。

2.1.2 技能提炼

在传统的上下文学习方法(in-context learning, ICL)中,LLM通常需要为每个查询准备一组演示示例^[24],并选择最合适的示例来优化性能。若利用强LLM从演示示例中提取解决问题的技能,以此作为原始提示示例的替代品,可以简化弱LLM的学习过程,引导弱LLM完成分类任务,产生超越传统ICL方法的效果,图3展示了这两种方法的流程及其效果的对比。




图3 两种ICL方法的流程及效果对比图

Fig.3 Comparison of process and results of two ICL methods

如图3所示,在技能提炼过程中,本文利用强LLM从训练集中提取出分类的关键技巧,包括分析思路、类别特征以及判断技巧等。考虑到LLM在上下文处理能力上的差异,设计了两种类型的技能框架:复杂技能(profound grimoire, PG)与简单技能(simple grimoire, SG)。代表性样本首先利用复杂提示词 P_1 生成PG集合。接着利用简单提示词 P_2 对PG进行化简得到SG集合。复杂提示词 P_1 与简单提示词 P_2 的内容如表1所示。

在与LLM交互时,提示词的效果与其提供的信息量和撰写的精细程度密切相关。提示词通常包括模型执行的特定任务或指令、引导模型生成更好响应的外部信息或背景信息、待回答的问题或输入数据,以及预期输出的类型或格式等内容。

表1 生成技能的提示词

Table 1 Prompt of generating grimoires

技能类型	提示词
复杂提示词 P_1	请根据下面的任务描述和示例,总结出解决主题分类的规则或技巧。 请注意,输出结果应满足: 1. 必要时可举例说明规则。 2. 需要给出应用规则的方法。 3. 不要太长。 任务:{任务描述} 示例:{代表性样本示例}
简单提示词 P_2	请用更简单明了的语言缩写以下内容,并尽量保留重要信息。 请注意,输出应满足: 1. 提供不超过三条一般规则。 2. 尽量简短。 内容:{复杂技能}

复杂提示词 P_1 旨在利用强 LLM,通过提供的任务描述和代表性样本,提炼出针对特定任务的通用解决方案,并提供对样本的解释和技能应用的方法,这反映了人类教师的教学方法,有助于弱 LLM 理解任务需求,并加速其对完成任务所需技能的学习。提示词最终还限制了输出的长度,这是为了防止技能超过弱 LLM 的上下文容量,因为过长的技能可能会产生负面影响。生成的复杂技能 PG 能够详尽阐述完成特定任务的方法,适用于上下文处理能力较强的 LLM,它综合了文本中的多种信息,并基于上下文和关键词判断进行精细分类,还能根据大量样本总结规律;而简单技能 SG 则是对 PG 的精简描述,侧重于快速识别和分类,它通过更直接的规则简化分类过程。这种方法虽然精细度不如 PG,但其适用于上下文处理能力有限的 LLM。

对于 HSS 抽样方法,为了提升模型学习困难样本的能力,在构建代表性样本示例时,本文将困难样本对应的错误答案也一同输入,同时在复杂提示词 P_1 中“应该满足的条件”部分加入“重点关注示例中错误答案与正确答案之间的区别”,以此让模型能通过对比错误答案来提升对易混淆类别的处理能力。

2.2 第二阶段:技能选择

针对 SLEICL 算法在技能选择上未能达到最优解的问题,本框架通过匹配问题中的关键词与技能,以实现更高效的选择过程。由于不同技能中涵盖了各类不同的关键词,该方法可以为性能较弱的 LLM 选择最有可能产生正确答案的技能,从而在每个查询下实现最佳效果。图4详细展示了这一选择过程的流程。

在第一阶段,本文采用了4种不同的样本选择方法,并基于每种方法生成了两种技能提示,因此共产生了8种技能实例:




图4 技能选择阶段流程图

Fig.4 Flowchart of skill selection phase

$$g_i \in G = \{KCS, HCS, HSS, RSS\} \times \{PG, SG\} \quad (4)$$

其中, G 代表技能候选集, g_i 代表候选集中的每一个技能。因为每个技能的侧重点不同,所以需要从中挑选出与待分类文本最契合的技能,即从候选集 G 中为测试数据集 T_d 的每个任务 q_j 确定最优技能 g^* :

$$\forall q_j \in T_d, g^* = \operatorname{argmax}_{g_i \in G} u(q_j; g_i | \mathbf{W}) \quad (5)$$

其中, $u(q_j; g_i | \mathbf{W})$ 表示在特定弱语言模型 $\mathbf{W}$ 上针对查询 q_j 的技能 g_i 的效用。为了定义这一效用函数,本文提出了关键词匹配环节,即基于弱 LLM 总结提炼出每个任务 q_j 的关键词集合 K_i ,再将 K_i 与候选技能 g_i 进行余弦相似度匹配,通过评估关键词与技能之间的匹配程度,用以预测技能在实际任务中的表现效果。

在提取关键词的过程中,本文设计了关键词提取提示词 P_3 , P_3 重点规定了提取关键词的步骤和技巧。

提取步骤包括:“1. 阅读摘要。彻底阅读并理解摘要。2. 初步列出。列出所有可能的关键词,考虑词频和理解程度。3. 过滤和优化删除关联词、合并同义词并确保唯一性。”

提取技巧:“1. 理解文本。充分理解摘要的主旨、论点和关键信息,考虑词语的上下文含义。2. 考虑词汇的重要性关注与该领域相关的核心术语和专业术语,平衡词频率与重要性。3. 利用领域专业知识准确确定相关的关键词,了解该领域的最新趋势和热点话题。4. 避免常见故障。排除停顿词,不要使用多义词,平衡关键词的具体性和消耗性。”利用关键词提取提示词 P_3 , 弱 LLM 能够准确地提取出反映文本内容的关键词。

随后,将关键词 K_i 与技能 g_i 进行余弦相似度匹配:

$$u_{\text{sim}}(K_j, g_i) = \cos(\text{embed}_{K_j}, \text{embed}_{g_i}) \quad (6)$$

其中, embed_{K_j} 代表已经通过嵌入模型转换为向量的关

关键词集合, $embed_{g_i}$ 代表候选技能集合的嵌入向量, 余弦相似度函数 u_{sim} 用于衡量二者之间的相似度, 从而选择出匹配度最高的技能。

接下来, 将最优技能嵌入到用于文本分类的提示词 P_4 中。该提示词不仅包括角色定义、任务说明、技能描述和输出格式等基础内容, 还引入了 Zhou 等人^[25]提出的自动提示工程师中的特定短语——“让我们循序渐进地找出正确答案”, 这一短语使得 LLM 在生成最终答案的过程中能够逐步展示其思考和推理步骤。与零样本思维链技术 (Zero-shot-CoT)^[26] 中的“让我们逐步思考”相比, 前者能够更有效地提高回答的准确性。

在分类完成后, 本文采用正则表达式技术捕捉答案中在制定标识“所属类别:”之后的分类结果。对于未能严格遵循既定格式输出的答案, 模型采用统计方法, 将答案中提及最为频繁的分类视为其最终归属。若答案内容未涉及任何预设的分类标签, 则视为无效回答, 此类情况将自动排除于准确率计算的考量范畴之外, 以确保评估结果的客观性与准确性。但上述数据将通过有效性记录下来, 以分析不合法数据的出现频率。

2.3 第三阶段: 技能库更新

现有的知识蒸馏算法虽然能有效保留旧类特征, 但常常导致对旧类的过度依赖, 影响模型对新类别的学习。此外, 多次前向计算增加了计算量和存储负担, 降低了效率。针对这些问题, 本文提出了一种基于知识蒸馏的动态调整机制。该机制通过融合新旧类别的特征, 动态平衡旧知识保留和新知识学习, 既能保留各类别特征, 又避免对新类学习的干扰。同时, 通过仅对新旧技能库进行分析和融合, 精简了计算和存储开销。

在这一模块, 对于属于新类别的样本, 模型遵循相同的机制自动生成新的技能库, 接着利用技能融合环节进行技能库扩充, 将新旧技能库利用强 LLM 通过融合提示整合起来, 其流程如图 5 所示。




图5 技能融合工作流程图

Fig.5 Workflow chart of skills integration

以任务 1 和任务 2 为例, 本文设计了融合提示词 P_5 ,

以此作为桥梁将两个独立任务下的技能库融合起来。 P_5 严格要求“1. 针对类别 {合并后的类别列表}, 重点挑选出与每个分类类别相关的内容, 最大化保留每个类别的分类技巧, 还有易混淆类别的判断技巧, 确保包含所有关键内容。2. 输出内容不要过长, 要求内容精简。”, 确保强 LLM 在维持所有类别特征的完整性 (包括其覆盖范围和归类逻辑) 的同时, 实现输出内容的高度凝练与简洁。融合后的技能不仅能包含各个类别的特征和代表性的关键词, 能够准确反映类别的核心属性, 同时, 对于那些在特征上相似、容易引发混淆的类别, 亦能进一步说明它们之间的细微差别, 输出有效的区分策略, 以提高分类的准确性和效率。

这一阶段保留了新旧类别的关键分类技巧, 有效平衡了旧知识保持与新知识学习的需求。通过不断地优化和调整, 技能库随着数据的更新而不断进化, 能够更好地适应新的分类需求和挑战。

3 实验与分析

3.1 实验环境

本文完成实验的硬件设备为 AMD6000 系统锐龙 7 处理器, 16 GB 内存, NVIDIA GeForce RTX 3050 显卡。实验的软件环境为深度学习框架 PyTorch, TensorFlow, Python3.8, Windows 11 操作系统。本文使用 GLM-4^[27] 作为较强的大语言模型, 使用 GLM-3 作为下游任务中的 LLM, 通过调用质谱开发平台的 GLM-4-0520 模型与 GLM-3-Turbo 模型的 API 完成实验。

3.2 实验设置

3.2.1 数据集

本文使用 THUCNews^[28] 中文新闻主题分类数据集进行 CIL 任务的评估。该数据集共有 10 个类别, 每个分类有 6 500 条数据, 总共 65 000 条新闻数据, 其中有 50 000 条训练集数据、5 000 条验证集数据以及 10 000 条测试集数据。本文将 THUCNews 数据集划分为 4 个不重叠的子集, 分别表示为 THU1、THU2、THU3 和 THU4。除了最后一个子集, 其余每个子集包含 3 个文本类别。这 4 个子集进一步被分为训练集、测试集、验证集, 表 2 显示了这 4 个子集的基本信息, 如表 2 所示。

表2 THUCNews 数据子集基本信息

Table 2 Basic information of THUCNews subset

数据子集	所含类别	训练集	测试集	验证集
THU1	体育、财经、房产	15 000	3 000	1 500
THU2	家居、教育、科技	15 000	3 000	1 500
THU3	时尚、时政、游戏	15 000	3 000	1 500
THU4	娱乐	5 000	1 000	500

3.2.2 参数设置

在第一阶段技能生成中,示例压缩环节用到的每个类别抽取的样本数 n 和 LLMLingua-2 的目标压缩比率 $\frac{1}{\tau}$ 是两个重要的参数,本文接下来将探究这两个参数的不同组合对于分类准确率的影响。Zhipu AI 研究团队^[27]对 GLM-4-0520 模型在处理长文本任务(基于中文数据集,上下文长度介于 10 000 至 100 000 字符之间)的性能进行了系统性的评估。研究发现,该模型在此上下文长度范围内表现出色。因此本文根据文本的平均长度,设计了 5 组不同的 n 和 $\frac{1}{\tau}$ 参数组合配置,以此控制问题表示(即 token 数量)在 80 000 左右。考虑到每个文本样本长度的非均一性,这一设置旨在确保在不超出 100 000 token 限制的前提下,最大化地利用 LLM 的上下文处理能力,从而优化模型在处理长文本时的综合性能。目标压缩比率 $\frac{1}{\tau}$ 、每个类别抽取的样本数 n 与问题的总长度 m 的关系为:

$$m = \bar{N} \times \tau \times n \times k \quad (7)$$

其中, $\bar{N}$ 表示原始样本的平均长度, k 是类别的数量。

实验中 $\frac{1}{\tau}$ 的取值设置为 1.5x、2x、3x、4x、5x,这参考了 LLMLingua-2 论文在 ShareGPT 和 Arxiv-March23 数据集上进行的实验的压缩率范围^[23]。接着依据式(7)计算出 n 的值,得到了 5 组 n 和 $\frac{1}{\tau}$ 的组合: (53, 1.5x)、(70, 2x)、(106, 3x)、(140, 4x)、(175, 5x)。图 6 展示了在不同 n 和 $\frac{1}{\tau}$ 组合的情况下, CIL-LLM 在完成所有任务之后,分别在之前第 i 个任务的准确率 $a_{4,1}$ 、 $a_{4,2}$ 、 $a_{4,3}$ 、 $a_{4,4}$ 以及第 4 个任务的平均准确率 A_4 。

图 6 中加粗标出了各个评估指标中的最高准确率,从图中可以看出,参数组合 (106, 3x) 在所有训练任务上




图6 不同参数组合下的分类准确率

Fig.6 Accuracy with various parameter combinations

平均准确率达 92.23%, 为最优组合, 且在前期任务中也表现优异, 显示出良好的跨任务适应性。对于采用较低压缩比率的情形, 因为受限于样本数量的不足, 难以充分捕捉并提炼出复杂多样的分类特征, 从而限制了模型性能的提升。相反, 当压缩比过高时, 样本数据在压缩过程中导致了关键信息的丢失, 这些信息的缺失直接影响了大语言模型 (LLM) 在分类任务中有效技能的提取与运用, 导致性能下滑。根据以上分析, 在后续所有实验中, 本文选择目标压缩比率 $\frac{1}{\tau}$ 为 3x、每个类别抽取的样本数 n 为 106 的参数设置组合进行实验。

3.2.3 实验步骤

为了科学评估增量学习算法的性能, 本文遵循了 Wang 等人^[10]先前研究中确立的实验方案, 并基于 THUCNews 数据集及其子集构建了一个序列化学习任务集, 命名为 THU-Seq。实验流程分为多个步骤进行: 首先, 在 CIL-LLM 框架的第一阶段, 使用 THU1 训练集生成初始技能库 G_1 , 并在第二阶段使用 THU1 测试集进行分类, 计算此时的准确率 $a_{1,1}$; 随后, 将 THU2 训练集输入框架的第一阶段, 生成新的技能库 G_{new} 后, 与技能库 G_1 共同输入框架的第三阶段, 得到更新后的技能库 G_2 ; 最后, 在第二阶段使用 THU1 测试集与 THU2 测试集进行测试, 计算在当前任务测试集上的准确率 $a_{2,2}$ 以及在之前任务上的准确率 $a_{2,1}$, 以此类推。在整个过程中, 4 个子集的训练集按照既定顺序逐一用于模型的阶段性训练。每完成一个任务后, 计算模型在当前任务测试集及之前各任务测试集上的分类准确率, 以全面评估其性能。当每个子集训练完毕(完成第 T 个任务)时, 需要计算该模型在当前任务测试集上的准确率 $a_{T,T}$ 以及之前任务上的准确率 $a_{T,i}$, i 为之前任务的序号。

在此过程, 本文使用平均准确度 (average accuracy) 和性能下降率 (performance drop rate) 作为 CIL 性能的评估指标。平均准确率能够反映模型在整个训练过程中的整体性能, 其计算公式如下:

$$A_T = \frac{1}{T} \sum_{i=1}^T a_{T,i} \quad (8)$$

其中, T 代表所有任务的数量, $a_{T,i}$ 代表模型在完成所有任务之后, 在第 i 个任务上的准确率。

性能下降率评估随着新类别的加入, 系统性能的下降低速度, 计算公式如式(9), 其中 A_j 表示第 j 个任务的平均准确率。

$$d = \frac{1}{T-1} \sum_{j=1}^{T-1} \frac{A_j - A_{j+1}}{A_j} \quad (9)$$

3.3 对比实验

在实验中, 本文将提出的方法与以下基线模型进行

了比较:

(1)微调(fine-tuning, FT):该方法按顺序对BERT(bidirectional encoder representations from transformers)模型进行微调,通常被视为持续学习(continual learning, CL)性能的下界评估标准。

(2)多任务学习(multi-task learning, MTL):该策略同时训练所有任务,由于能够同时访问所有任务的数据,常被视作持续学习性能的上界评估标准。

(3)学习无遗忘(learning without forgetting, LwF):Li和Hoiem^[29]提出的LwF方法利用在前一个任务上训练的旧模型来预测新任务的数据,并通过知识蒸馏来防止遗忘。此方法需要存储旧模型在新数据上的预测结果。

(4)弹性权重巩固(elastic weight consolidation, EWC):Kirkpatrick等人^[6]提出的EWC方法通过选择性减缓对旧任务重要参数的学习速率来避免遗忘。该方法为每个参数维护“估计均值”和“信息矩阵”的估计值。

(5)R-Walk:Chaudhry等人^[30]在EWC++和路径积分的基础上提出了一种泛化方法,即R-Walk。该方法需要存储信息矩阵以及每个参数的分数。

(6)记忆感知突触(memory aware synapses, MAS):Aljundi等人^[31]提出的MAS方法根据输出对每个参数变化的敏感度,累积每个参数的重要性度量。该方法存储了每个参数的重要性信息。

(7)并行适配器(AdapterParallel):Houlsby等人^[32]提出的AdapterParallel方法为每个任务训练一组独立的适配器。在测试时,本文对所有模型进行预测,并选择预测分数最高的标签作为最终结果。然而,这种方法的推理开销会随着任务数量的增加而线性增长,因此在实际应用中可能不太高效。

(8)堆叠适配器(AdapterStack):随着新任务的加入,Pfeiffer等人^[33]提出AdapterStack方法,该方法增量地堆叠新的适配器。在训练过程中,保持之前的适配器不变,仅对最新的适配器进行微调。

(9)适配器融合(AdapterFusion):Pfeiffer等人^[34]提出的适配器融合方法通过学习一个适配器融合模块来利用现有的适配器。

(10)基于轻量级快照算法(L-SCL):Wang等人^[10]提出的L-SCL方法通过知识蒸馏将过去快照中的知识转移到新模型中。该方法设计了表示重新校准,以更好地处理类增量设置。

表3总结了不同方法在THU-Seq任务上的结果,表中加粗标出了除了MTL上界评估标准之外,各任务的最高平均准确率。CIL-LLM方法结果的有效性普遍高于98%,由于表格展示限制,这一点未在表中标出。 A_i

表3 THU-Seq 任务实验结果

Table 3 Experimental results of

THU-Seq mission

单位:%

模型	A_1	A_2	A_3	A_4	d
MTL	99.0	95.3	95.9	95.7	1.1
FT	98.9	61.2	37.1	27.4	34.5
LwF	98.9	76.8	53.0	43.8	23.6
EWC	98.9	82.5	54.6	51.8	18.5
R-Walk	98.9	84.9	81.2	73.5	9.3
MAS	98.9	86.4	82.3	60.1	14.8
AdapterParallel	98.7	72.0	71.6	69.4	10.2
AdapterStack	98.7	55.6	50.7	33.3	28.9
AdapterFusion	98.7	52.7	36.2	26.5	34.9
L-SCL	98.9	87.9	89.2	86.3	4.3
CIL-LLM	96.0	94.9	93.5	92.6	1.2

表示第 i 个任务的平均准确率, d 代表性能下降率。从表3中可以看出,对于各个任务的平均准确率 A_i ,除了 A_1 以外,CIL-LLM在所有任务中的平均准确率都比其他方法高,尤其相比于L-SCL模型,CIL-LLM在所有任务上的平均准确率 A_4 超出其6.3个百分点。这表明,CIL-LLM模型在处理增量任务时,能够更好地保持高水平的准确率。关于评估指标 A_1 ,由于任务1利用仅含3种类别的数据子集THU1进行训练和测试,属于相对简单的分类任务。对于此类任务,深度学习模型由于是针对特定任务进行设计和优化的,能更有效地利用任务相关特征,并通过减少模型复杂度和避免过拟合来实现更好的泛化性能,从而实现更高的分类准确率。因此,在第一个任务中,其他基线模型展现出了更好的准确率。对于性能下降率 d ,随着任务的不断进行,模型的平均准确率普遍降低。其中,CIL-LLM的性能下降率相比于其他基线模型更低,以已有的L-SCL模型为例,CIL-LLM的性能下降率低于其3.1个百分点。说明该模型在应对任务之间的转移时,表现得更为稳定,具有更强的适应性和泛化能力。

3.4 消融实验

为了验证CIL-LLM框架各环节的效果,本文在THUCNews数据集上进行了消融实验,具体结果如表4所示。在消融实验中,本文通过在未经修改的SLEICL模型上依次增加环节来探索各环节的作用。示例压缩是指在技能生成阶段,对代表性样本实施压缩并扩增样本量;关键词匹配是在技能选择过程中,先提取关键词再行余弦相似度比对;技能融合是对新旧技能库进行精准整合。

消融实验结果表明,相比于直接使用SLEICL模

表4 消融实验结果

Table 4 Results of ablation experiment 单位:%

示例压缩 环节	关键词 匹配环节	技能融 合环节	A_4	d
			82.2	4.5
√			88.1(+5.9)	3.8(-0.7)
	√		90.3(+8.1)	3.9(-0.6)
		√	87.8(+5.6)	1.9(-2.6)
√	√		92.5(+10.3)	3.0(-1.5)
√		√	91.0(+8.8)	1.6(-2.9)
	√	√	91.4(+9.2)	1.5(-3.0)
√	√	√	92.6(+10.4)	1.2(-3.3)

型, CIL-LLM 在所有任务上的平均准确率 A_4 提升了 10.4 个百分点, 性能下降率降低了 3.3 个百分点。此外, 本文提出的示例压缩、关键词匹配和技能融合环节都对提高类别增量学习性能有贡献, 并且它们的结合比单独使用任意一个环节表现更好, 证明了示例压缩环节显著提升了生成技能的质量, 关键词匹配环节有效解决了无法匹配最优技能的问题, 技能融合环节有效降低了性能下降率, 显著缓解了灾难性遗忘问题。

4 结束语

本文提出了 CIL-LLM 框架, 旨在解决文本分类领域类别增量学习任务中的挑战, 为使用大语言模型解决类别增量学习任务提供了新的方向。

本文从提升模型的分类准确性、存储效率和新旧类别特性学习能力出发, 基于已有研究, 构建了 CIL-LLM 框架。该框架通过引入样本压缩、关键词匹配和技能融合三个环节, 首先从训练集中提取关键技能, 接着挑选与待分类文本最契合的技能以构建提示词, 最后更新和扩展技能库, 有效提升了类别增量学习中的分类性能和稳定性。通过在 THUCNews 数据集上进行充分的参数选择、对比和消融实验, 结果表明, CIL-LLM 框架在学习所有任务后的平均准确率和性能下降率均优于基线模型, 同时各环节对性能的优化效果也得到了验证。

尽管该模型已取得了显著的进展, 但仍有进一步优化和拓展的空间。未来研究可以关注以下方向: (1) 针对易混淆类别进行特征细化和增强, 尝试调整硬样本选择(HSS)中错误样本的比例或优化技能提示词的方法; (2) 扩展到层次分类体系, 以提高模型的实用性和应对复杂任务的能力, 可探索树状结构的层次分类器构建; (3) 增强模型在开放动态环境中的适应性, 集成开放集识别功能以区分已知和未知类, 并开发新类发现能力, 通过结合大语言模型与技能库实现新类别数据的判别和识别。

参考文献:

- [1] ZHANG Y J, ZHAO P, MA L, et al. An unbiased risk estimator for learning with augmented classes[C]//Advances in Neural Information Processing Systems 33, 2020: 10247-10258.
- [2] XU M, GUO L Z. Learning from group supervision: the impact of supervision deficiency on multi-label learning[J]. Science China Information Sciences, 2021, 64(3): 130101.
- [3] MCCLOSKEY M, COHEN N J. Catastrophic interference in connectionist networks: the sequential learning problem [M]//Psychology of learning and motivation. Elsevier, 1989: 109-165.
- [4] WANG Z R, MEHTA S V, POCZOS B, et al. Efficient meta lifelong-learning with limited memory[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2020: 535-548.
- [5] LOPEZ-PAZ D, RANZATO M A. Gradient episodic memory for continual learning[C]//Advances in Neural Information Processing Systems 30, Long Beach, Dec 4-9, 2017: 6467-6476.
- [6] KIRKPATRICK J, PASCANU R, RABINOWITZ N, et al. Overcoming catastrophic forgetting in neural networks[J]. Proceedings of the National Academy of Sciences, 2017, 114(13): 3521-3526.
- [7] YAN S, XIE J, HE X. DER: dynamically expandable representation for class incremental learning[C]//Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 3013-3022.
- [8] WU Y, CHEN Y, WANG L, et al. Large scale incremental learning [C]//Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 374-382.
- [9] YIN W P, LI J, XIONG C M. ConTinTin: continual learning from task instructions[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2022: 3062-3072.
- [10] WANG J, DONG D, SHOU L, et al. Effective continual learning for text classification with lightweight snapshots [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(8): 10122-10130.
- [11] CHEN D, SONG S, YU Q, et al. Grimoire is all you need for enhancing large language models[EB/OL]. [2024-07-22]. <https://arxiv.org/abs/2401.03385>.
- [12] LIU P F, QIU X P, HUANG X J. Recurrent neural network for text classification with multi-task learning[C]//Proceedings of the 25th International Joint Conference on Artificial Intelligence. Menlo Park: AAAI, 2016: 2873-2879.
- [13] CONNEAU A, SCHWENK H, BARRAULT L, et al. Very deep convolutional networks for text classification[C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2017: 1107-1116.
- [14] YAO L, MAO C S, LUO Y. Graph convolutional networks

- for text classification[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 905.
- [15] JOULIN A, GRAVE E, BOJANOWSKI P, et al. Bag of tricks for efficient text classification[C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2017: 427-431.
- [16] SCHICK T, SCHÜTZE H. Exploiting cloze-questions for few-shot text classification and natural language inference [C]//Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2021: 255-269.
- [17] HAN X, ZHAO W, DING N, et al. PTR: prompt tuning with rules for text classification[J]. AI Open, 2022, 3: 182-192.
- [18] SHI W J, MICHAEL J, GURURANGAN S, et al. Nearest neighbor zero-shot inference[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2022: 3254-3265.
- [19] DE MASSON D' AUTUME C, RUDER S, KONG L, et al. Episodic memory in lifelong language learning[C]//Advances in Neural Information Processing Systems 32, Vancouver, Dec 8-14, 2019: 13122-13131.
- [20] ZHOU D W, YE H J, ZHAN D C. Learning placeholders for open-set recognition[C]//Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 4399-4408.
- [21] ZHAO B, XIAO X, GAN G, et al. Maintaining discrimination and fairness in class incremental learning[C]//Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 13205-13214.
- [22] GPT-4 turbo preview: exploring the 128k context window [EB/OL]. [2024-07-22]. <https://povio.com/blog/gpt-4-turbo-preview-exploring-the-128k-context-window/>.
- [23] PAN Z, WU Q, JIANG H, et al. LLMingua-2: data distillation for efficient and faithful task-agnostic prompt compression[EB/OL]. [2024-07-22]. <http://arxiv.org/abs/2403.12968>.
- [24] RUBIN O, HERZIG J, BERANT J. Learning to retrieve prompts for in-context learning[C]//Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2022: 2655-2671.
- [25] ZHOU Y, MURESANU A I, HAN Z, et al. Large language models are human-level prompt engineers[EB/OL]. [2024-08-13]. <http://arxiv.org/abs/2211.01910>.
- [26] KOJIMA T, GU S S, REID M, et al. Large language models are zero-shot reasoners[EB/OL]. [2024-08-13]. <http://arxiv.org/abs/2205.11916>.
- [27] GLM T, ZENG A, XU B, et al. ChatGLM: a family of large language models from GLM-130B to GLM-4 all tools[EB/OL]. [2024-07-22]. <http://arxiv.org/abs/2406.12793>.
- [28] Papers with Code-THUCNews dataset[EB/OL]. [2024-07-22]. <https://paperswithcode.com/dataset/thucnews>.
- [29] LI Z, HOIEM D. Learning without forgetting[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(12): 2935-2947.
- [30] CHAUDHRY A, DOKANIA P K, AJANTHAN T, et al. Riemannian walk for incremental learning: understanding forgetting and intransigence[C]//Proceedings of the 15th European Conference on Computer Vision. Cham: Springer, 2018: 556-572.
- [31] ALJUNDI R, BABILONI F, ELHOSEINY M, et al. Memory aware synapses: learning what (not) to forget[C]//Proceedings of the 15th European Conference on Computer Vision. Cham: Springer, 2018: 144-161.
- [32] HOULSBY N, GIURGIU A, JASTRZEBSKI S, et al. Parameter-efficient transfer learning for NLP[C]//Proceedings of the 36th International Conference on Machine Learning, Long Beach, Jun 9-15, 2019: 2790-2799.
- [33] PFEIFFER J, VULIĆ I, GUREVYCH I, et al. MAD-X: an adapter-based framework for multi-task cross-lingual transfer [C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2020: 7654-7673.
- [34] PFEIFFER J, KAMATH A, RÜCKLÉ A, et al. AdapterFusion: non-destructive task composition for transfer learning[C]//Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2021: 487-503.



王晓宇(2001—),女,湖北宜昌人,硕士研究生,CCF学生会会员,主要研究方向为大语言模型、风险评估等。

WANG Xiaoyu, born in 2001, M.S. candidate, CCF student member. Her research interests include large language models, risk assessment, etc.



李欣(1977—),男,博士,教授,CCF会员,主要研究方向为人工智能、网络安全等。

LI Xin, born in 1977, Ph.D., professor, CCF member. His research interests include artificial intelligence, network security, etc.



胡勉宁(2000—),男,四川达州人,硕士研究生,主要研究方向为网络安全、风险评估、自然语言处理等。

HU Mianning, born in 2000, M.S. candidate. His research interests include cybersecurity, risk assessment, natural language processing, etc.



薛迪(2001—),男,山东临沂人,硕士研究生,主要研究方向为视觉问答、大语言模型等。

XUE Di, born in 2001, M.S. candidate. His research interests include visual Q&A, large language model, etc.